

Clébio Júnior

CIENTISTA DE DADOS

E-mail: clebiomojunior@gmail.com
LinkedIn: linkedin.com/in/clebiojunior
GitHub: github.com/juniorcl
Blog: medium.com/@juniorcl

RESUMO PROFISSIONAL

Cientista de Dados com mais de 5 anos de experiência na aplicação de machine learning, estatística e análise de dados para resolver problemas reais de negócio com impacto mensurável. Atuação em projetos de modelagem preditiva para credit scoring, previsão de vendas, previsão de demanda logística, detecção de anomalias, segmentação de clientes e análise de comportamento do consumidor nos setores de risco de crédito, jurídico e varejo. Experiência sólida com dados estruturados e não estruturados, incluindo extração e processamento de texto com NLP e OCR. Mestre em Ciências Naturais, com forte base quantitativa em estatística, modelagem e interpretação de resultados para áreas de negócio.

COMPETÊNCIAS TÉCNICAS

- **Linguagens de Programação:** Python, SQL, C/C++
- **Machine Learning:** Aprendizado Supervisionado, Aprendizado Não Supervisionado, Classificação, Regressão, Clustering, Modelagem Preditiva, Feature Engineering, Feature Selection, Validação Cruzada, Otimização de Hiperparâmetros
- **Algoritmos:** Regressão Logística, Random Forest, XGBoost, LightGBM, CatBoost, KNN, SVM, K-Means, Gaussian Mixture Models
- **Estatística e Análise:** Estatística Descritiva e Inferencial, Análise Exploratória de Dados (EDA), Análise de Séries Temporais, Testes de Hipóteses, Detecção de Outliers, Análise de Coorte
- **NLP e Dados Não Estruturados:** spaCy, NLTK, Embeddings, Classificação de Texto, Tokenização, Lematização, OCR (Tesseract), pdfplumber, Expressões Regulares (Regex)
- **Bibliotecas e Ferramentas:** pandas, NumPy, scikit-learn, SciPy, Matplotlib, Seaborn, Plotly, Optuna, SHAP, Boruta, Jupyter Notebook
- **Engenharia e Deploy:** Flask, APIs REST, Docker, Git, GitHub, Linux
- **Metodologias:** CRISP-DM, Métricas de Negócio, Testes A/B, Metodologias Ágeis

EXPERIÊNCIA PROFISSIONAL

Cientista de Dados — Vert Analytics

Outubro/2024 – Atual | Remoto

- Conduzo projetos de exploração, análise e modelagem de dados estruturados e não estruturados voltados à geração de insights estratégicos, com entrega de resultados em dashboards interativos em SAS.
- Desenvolvi sistema de recomendação de defesas jurídicas baseado em NLP, embeddings e busca vetorial com FAISS, reduzindo o tempo de pesquisa manual e aumentando a acurácia das decisões tomadas pela equipe.
- Construí pipelines automatizados de extração e limpeza de dados a partir de arquivos PDF, incluindo documentos digitalizados, utilizando pdfplumber, Tesseract OCR e expressões regulares, estruturando informação antes indisponível para análise.
- Implementei solução de análise de texto com spaCy para classificar reclamações de clientes em redes sociais, aplicando tokenização, lematização, remoção de stopwords e correção gramatical para identificar temas recorrentes.
- Realizo análises de séries temporais para identificação de padrões e anomalias, apoiando decisões de produto, atendimento e operação.

Cientista de Dados — Datarisk

Janeiro/2022 – Agosto/2024 | Remoto

- Desenvolvi modelo de credit scoring baseado em machine learning para estimar a probabilidade de pagamento a partir do histórico financeiro dos clientes, aprimorando os critérios de concessão de crédito e a eficiência da gestão de risco.
- Criei modelo de regressão para previsão de volume de vendas a partir de dados históricos, com pré-processamento, feature engineering e otimização de hiperparâmetros, passando a apoiar o planejamento estratégico da área comercial.
- Apliquei algoritmos de clustering para segmentação da base de clientes, identificando perfis comportamentais distintos e viabilizando estratégias de relacionamento direcionadas.
- Executei todo o ciclo analítico de limpeza, exploração e análise de dados, traduzindo problemas de negócio em soluções de machine learning e apresentando resultados a áreas não técnicas.

Cientista de Dados — Be.X!

Março/2021 – Janeiro/2022 | Remoto

- Desenvolvi projetos de análise de dados estruturados e não estruturados com o objetivo de criar algoritmos de machine learning capazes de gerar insights automatizados para clientes.
- Processei grandes volumes de dados textuais não estruturados com expressões regulares para limpeza e extração de informação, aumentando significativamente a disponibilidade de dados para tomada de decisão.
- Implementei algoritmos de detecção de outliers baseados em regras de negócio para sinalizar anomalias operacionais, contribuindo para a mitigação de riscos e para decisões estratégicas mais confiáveis.
- Desenvolvi modelo preditivo para estimar a probabilidade de atraso na entrega de pedidos, utilizando métricas de ranqueamento para priorizar as entregas de maior risco e viabilizar ações preventivas na operação logística.

PROJETOS SELECIONADOS

- **Detecção de Fraude em Transações** — Modelo de classificação para identificação de transações fraudulentas em dados altamente desbalanceados, com feature engineering, seleção de variáveis com Boruta e ajuste de hiperparâmetros. O modelo final em XGBoost alcançou 91,5% de acurácia balanceada e 94,4% de precisão em dados não vistos. Projeto com mais de 220 estrelas no GitHub. (github.com/juniorcl/transaction-fraud-detection)
- **Previsão de Prazo de Entrega em E-commerce (Olist)** — Modelo de regressão com LightGBM para prever o tempo de entrega de pedidos, com dados consumidos via SQL de banco containerizado em Docker, seleção de variáveis com mRMR, otimização com Optuna e interpretabilidade com SHAP. Redução de 66% no MAE frente à regra de negócio vigente, com deploy em API Flask. (github.com/juniorcl/olist-delivery-forecast)
- **DSToolkit — Biblioteca Python de Ciência de Dados** — Biblioteca modular com API inspirada no scikit-learn, reunindo pipelines de AutoML para classificação, regressão e clustering, métricas de avaliação (ROC, PR, KS, curvas de calibração, métricas de lift), diagnósticos de resíduos e utilitários de feature engineering. (github.com/juniorcl/data-science-toolkit)
- **Previsão de Vendas Rossmann** — Modelo de regressão para previsão de vendas diárias de lojas com até seis semanas de antecedência, incluindo análise exploratória, formulação e validação de hipóteses de negócio.
- **Health Insurance Cross-Sell** — Modelo de ranqueamento de clientes para aumentar a eficiência de campanhas de venda cruzada de seguros, avaliado com curvas de ganho acumulado e lift.

Portfólio completo disponível em juniorcl.github.io e github.com/juniorcl.

FORMAÇÃO ACADÊMICA

Mestrado em Ciências Naturais — Ciência Ambiental

Universidade Estadual do Norte Fluminense (UENF) | 2017 – 2019

Licenciatura em Ciências Naturais — Física

Instituto Federal Fluminense (IFF) | 2010 – 2016

CERTIFICAÇÕES E CURSOS

- Quickstart: LangGraph Essentials — Python
- Clustering: Extraíndo Padrões de Dados
- Reconhecimento de Textos com OCR e Python
- Formação em Ciência de Dados — Comunidade DS
- Estatística Aplicada — Comunidade de Estatística do Prof. Thiago Marques
- Estatística e Otimização para Ciência de Dados e Pesquisa Operacional — USP
- MLOps: Deploy de Modelos e APIs de Machine Learning

IDIOMAS

- **Português:** Nativo
- **Inglês:** Profissional completo
- **Esperanto:** Profissional completo